Bayesian Survival Analysis on CHR-P

Misaki et al. *Molecular Psychiatry*, 2025

Ido JI

Brain Development Imaging Lab, Korea Brain Research Institute (KBRI)
Department of Medical Sciences, Kyungpook National University

January 23, 2026

Methods roadmap: Bayesian mixture cure model

- CHR-P 추적자료: 관찰 종료 시점까지 미발병(검열) 대상이 다수 ⇒ mixture cure로 (i) incidence vs (ii) latency 분리
- Population survival:

$$S_{\text{pop}}(t \mid \cdot) = (1 - \Pi_i) + \Pi_i \, S_u(t \mid \mathbf{w}_i)$$

- Incidence component: Π_i (susceptible = non-cure일 확률) ⇒ 로지스틱 회귀 + 외부역학 기반 shape prior
- Latency component: $S_u(\cdot)$ (susceptible 집단 내 전환시간 분포) ⇒ Cox(attained-age) + AFT(time-on-study) 후보모형 비교
- 핵심 아이디어: Shape–Level 분리 (shape는 문헌에서, level은 데이터에서) + 절편 이동(shift) Δ

Incidence component: Π_i의 의미(장기 감수성; non-cure probability)

- Π_i는 개인 i가 susceptible(=non-cure) 집단에 속할 확률
- mixture cure 해석에서 Π_i는 $t \to \infty$에서의 uncured fraction에 대응 (관찰 종료 시점과 무관한 장기 운명 파라미터)
- CHR-P 자료에서는 검열이 많아 Π_i와 S_u의 분리가 어려울 수 있음 $\Rightarrow$ incidence에 역학적 안정화(prior anchoring) 필요
- 본 연구: incidence에서 sex $\times$ age strata만 사용하여 외부 문헌의 상대적 대비(contrast)를 prior mean에 이식

Shape–Level 분리 원리: 왜 Δ가 필요한가?

- 외부 문헌(일반 인구)은 성별/연령별 상대적 패턴(shape)을 안정적으로 제공
- 그러나 CHR-P 코호트의 절대 위험 수준(level)은
  - 일반 인구와 다를 수 있고,
  - 연간 발생률(rate) vs 장기 감수성(Π)의 시간지평 불일치로 인해 필연적 수준 차이 존재
- 해결: prior에서
  - shape는 문헌 기반 contrast로 회귀계수 prior mean에 반영
  - level은 공통 절편 이동 Δ가 우도(데이터)로부터 학습하도록 분리
- Δ는 "보정항"이라기보다 전반적 수준 불일치(level mismatch)를 흡수하는 자유도

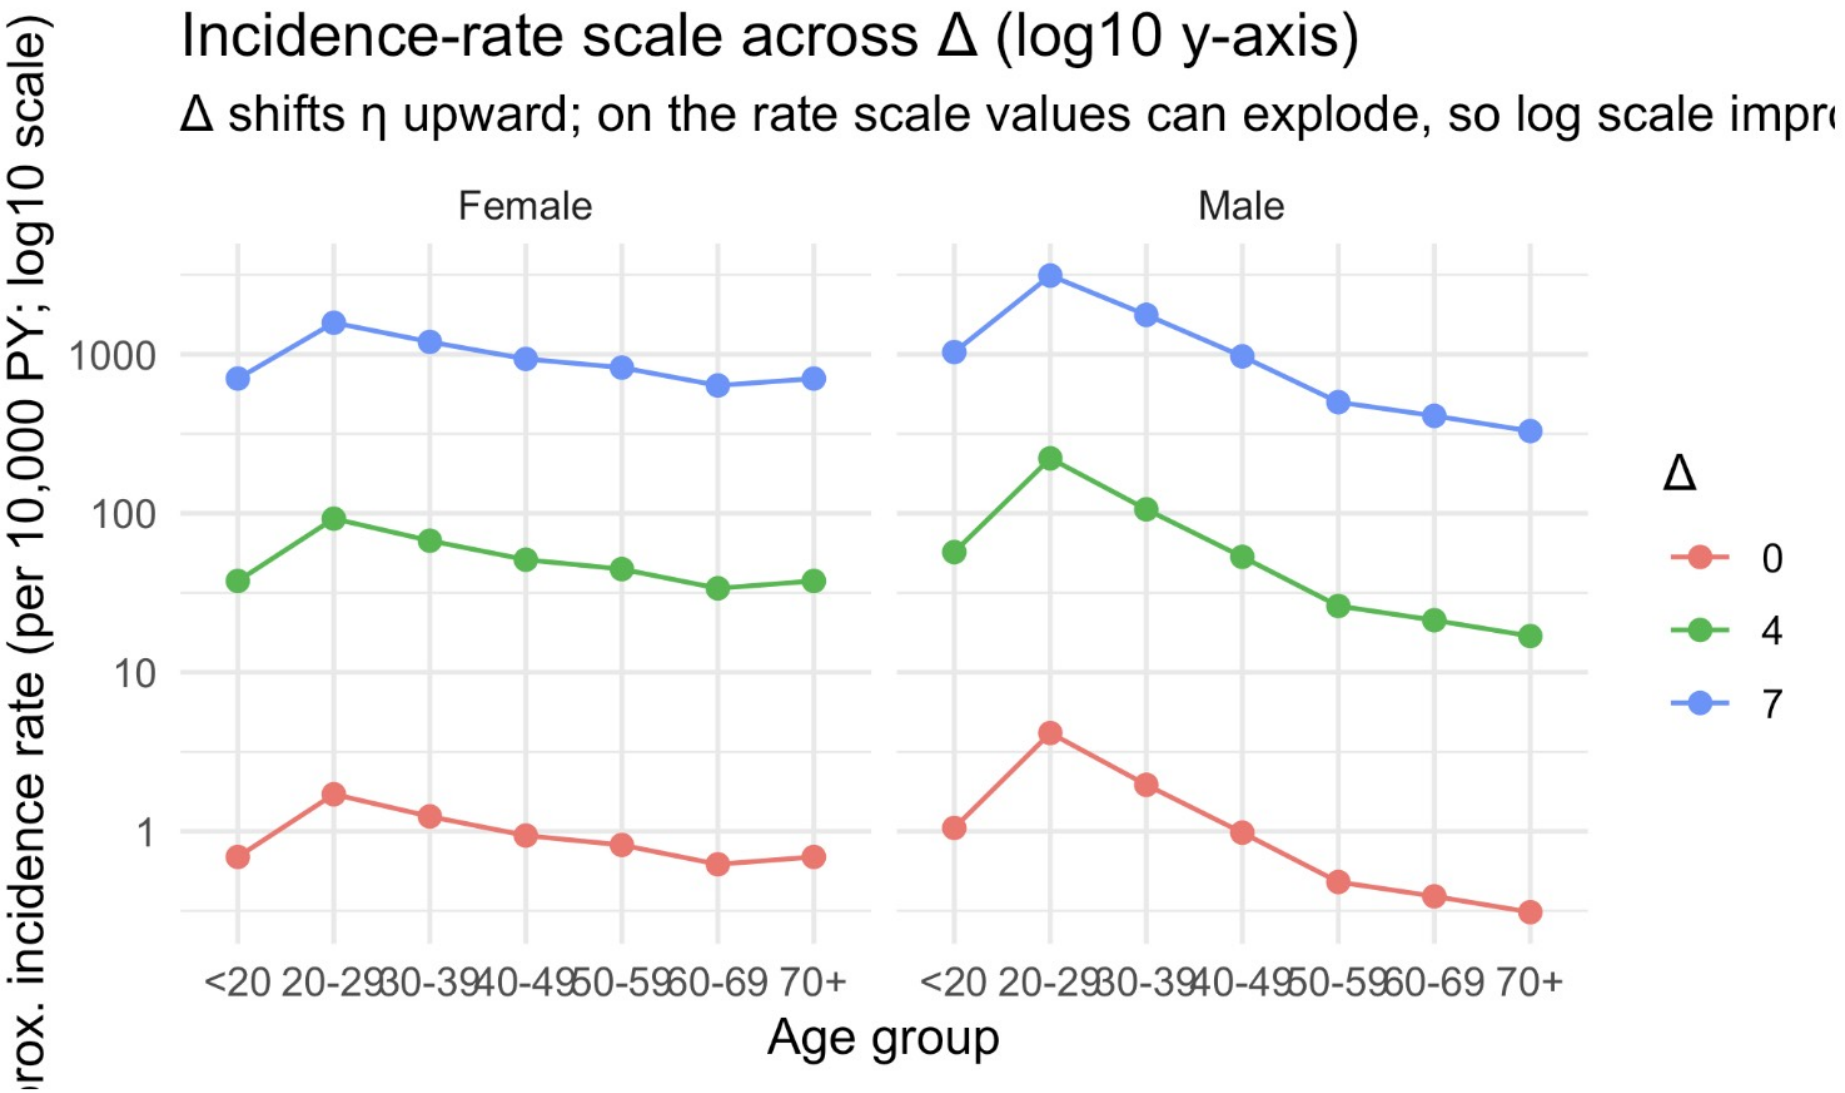
Incidence-rate scale across Δ (log10 y-axis)
Δ shifts η upward; on the rate scale values can explode, so log scale impr
Female
Male
1000
100
10
1
<20 20-29 30-39 40-49 50-59 60-69 70+
<20 20-29 30-39 40-49 50-59 60-69 70+
Age group
rox. incidence rate (per 10,000 PY; log10 scale)
Δ
0
4
7

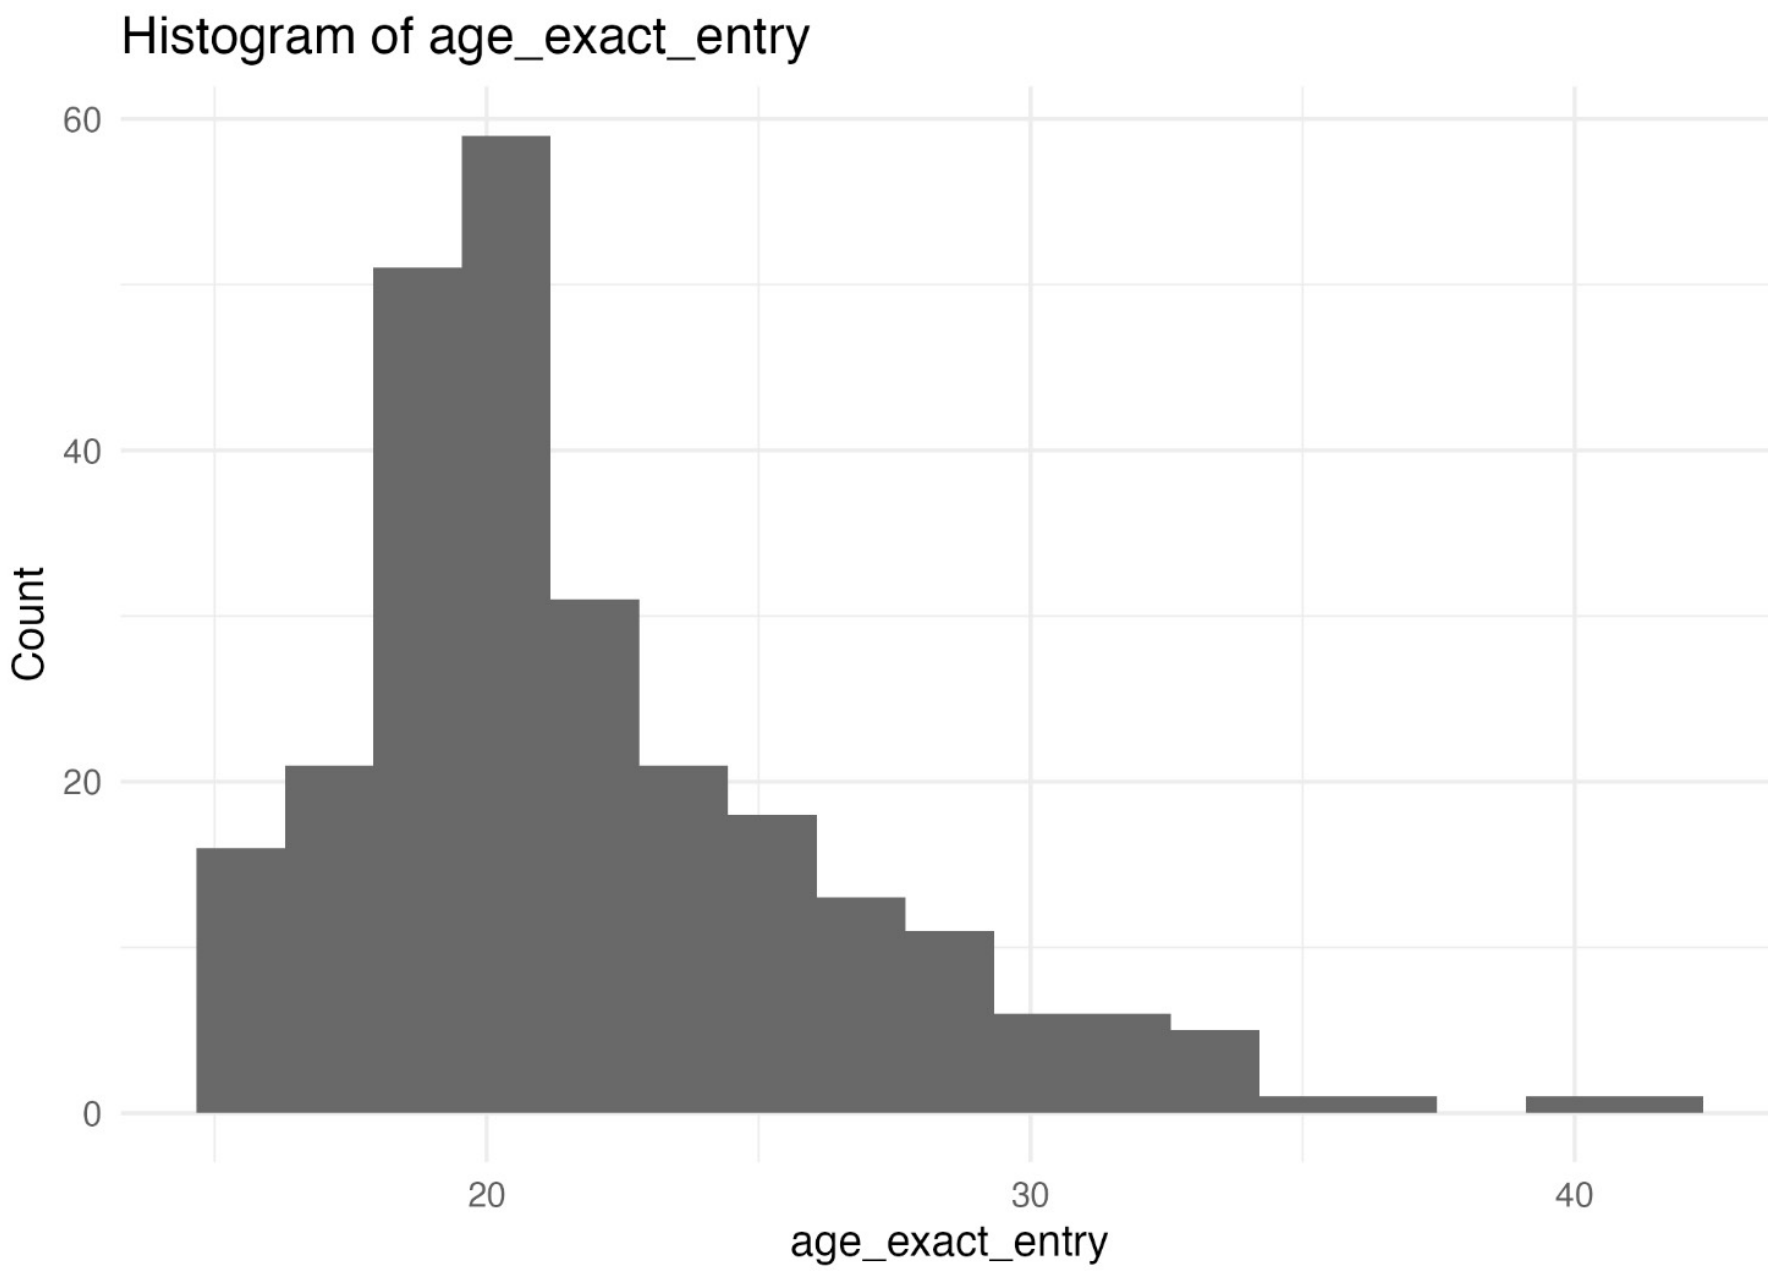
Histogram of age_exact_entry
60
40
20
0
Count
20
30
40
age_exact_entry

Logit anchor 대비(contrast)로 prior mean 구성

- 기준 strata: 여성 < 20세를 $k = 1$로 두고

$$\alpha_0^{(\mathrm{GP})} \equiv y_{\mathrm{F},<20}(1) \approx -9.5813 \quad \text{(fixed)}$$

- 남성 효과(기준 연령에서)

$$\mu_{\text{Male}} = y_{\mathrm{M},<20}(1) - y_{\mathrm{F},<20}(1)$$

- 여성 연령 효과(기준 연령 대비)

$$\mu_{a_j} = y_{\mathrm{F},a_j}(1) - y_{\mathrm{F},<20}(1)$$

- 상호작용(연령대별 남녀 격차 변화)

$$\mu_{\text{Male}\times a_j} = \left(y_{\mathrm{M},a_j} - y_{\mathrm{F},a_j}\right) - \left(y_{\mathrm{M},<20} - y_{\mathrm{F},<20}\right)$$

- 위 대비들은 로짓 스케일에서 log-OR로 해석 가능

Incidence 로지스틱 모형: Δ 포함 선형예측자

- $$\Pi_i = \text{logit}^{-1}(\eta_i)$$
- sex × age strata 로지스틱 선형예측자

$$\eta_i = \alpha_F + \mathbb{I}(s_i = M)(\alpha_M - \alpha_F) + \sum_{j=2}^{7} \beta_{a_j} \mathbb{I}(a_i = a_j) + \sum_{j=2}^{7} \beta_{\text{Male} \times a_j} \mathbb{I}(s_i = M \wedge$$

- 절편 분해(Shape–Level 분리)

$$\alpha_F \equiv \alpha_0^{(\text{GP})} + \Delta, \qquad \alpha_M \equiv \alpha_0^{(\text{GP})} + \Delta + \beta_{\text{Male}}$$

- 해석: Δ는 log-odds에 가산, odds에는 곱셈적 배수 exp(Δ)로 작동

[표 1-a] Reference data (Van der Werf 2014): Female strata

- 문헌의 median crude rate $\Rightarrow p(1) \approx r$, $y = \text{logit}(p)$로 변환한 목표 log-odds(anchor): Female

Age (years)	r **(per 10,000 PY)**	$\tilde{p}$	**Target** y
< 20	0.69	0.000069	-9.5813
20–29	1.71	0.000171	-8.6737
30–39	1.24	0.000124	-8.9951
40–49	0.94	0.000094	-9.2721
50–59	0.82	0.000082	-9.4087
60–69	0.62	0.000062	-9.6883
70+	0.69	0.000069	-9.5813

Note. r는 Van der Werf et al. (2014) Table 2의 *Median crude rate*.

[표 1-b] Reference data (Van der Werf 2014): Male strata

- 동일 변환을 Male strata에 적용한 목표 log-odds(anchor): Male

Age (years)	r **(per 10,000 PY)**	$\tilde{p}$	**Target** y
< 20	1.05	0.000105	-9.1614
20–29	4.15	0.000415	-7.7868
30–39	1.96	0.000196	-8.5372
40–49	0.98	0.000098	-9.2304
50–59	0.48	0.000048	-9.9443
60–69	0.39	0.000039	-10.1519
70+	0.31	0.000031	-10.3815

Note. r는 Van der Werf et al. (2014) Table 2의 *Median crude rate*.

[표 2] Incidence prior means: 계수(μ_0)와 OR

- $\alpha_0^{(\mathrm{GP})}$는 고정 상수 (회귀계수 벡터에 포함되지 않음)
- Δ는 level 조정, 나머지 β는 shape(대비 구조) 앵커링

Category	Parameter	μ_0	OR $= e^{\mu_0}$
Fixed anchor	$\alpha_0^{(\mathrm{GP})}$	-9.5813	–
Shift (level)	Δ	0.0000	1.00
Male effect	β_{Male}	0.4199	1.52
Female age	β_{20-29}	0.9077	2.48
	β_{30-39}	0.5862	1.80
	β_{40-49}	0.3092	1.36
	β_{50-59}	0.1726	1.19
	β_{60-69}	-0.1070	0.90
	β_{70+}	0.0000	1.00
Interaction	$\beta_{\mathrm{Male}\times 20-29}$	0.4670	1.60
	$\beta_{\mathrm{Male}\times 30-39}$	0.0380	1.04
	$\beta_{\mathrm{Male}\times 40-49}$	-0.3782	0.69
	$\beta_{\mathrm{Male}\times 50-59}$	-0.9554	0.38
	$\beta_{\mathrm{Male}\times 60-69}$	-0.8835	0.41
	$\beta_{\mathrm{Male}\times 70+}$	-1.2200	0.30

Shift prior: $\Delta \sim \mathcal{N}(0, 3.5^2)$ 설정 논리

- 목표: 코호트 level이 일반인구 수준일 수도, CHR-P 수준일 수도 있음을 사전적으로 허용
- Δ는 log-odds에 더해지므로 $\exp(\Delta)$는 odds 배수
- 약 95% 범위를 $\pm 2\sigma$로 보면

$$\Delta \in [-7,\, 7] \quad \Rightarrow \quad \exp(7) \approx 1{,}096$$

- 해석: Δ는 (i) 코호트 vs 일반인구 기저 위험 차이, (ii) annual rate vs long-term Π의 스케일 차이를 단일 공통 이동으로 흡수

Incidence prior distribution: $\theta \sim \mathcal{N}(\mu_0, \Sigma_0)$

- 추정 파라미터 벡터(고정 anchor 제외)

$$\boldsymbol{\theta} = \left(\Delta,\ \beta_{\text{Male}},\ \beta_{a_2}, \ldots, \beta_{a_7},\ \beta_{\text{Male}\times a_2}, \ldots, \beta_{\text{Male}\times a_7}\right)^\top$$

- 다변량 정규 prior

$$\boldsymbol{\theta} \sim \mathcal{N}_p(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$$

- 기본 설정(독립; 대각 공분산)

$$\boldsymbol{\Sigma}_0 = \mathrm{diag}\left(\sigma_\Delta^2, \sigma_\beta^2, \ldots, \sigma_\beta^2\right), \qquad \sigma_\Delta = 3.5,\ \sigma_\beta = 1.0$$

- 결과: shape는 mean으로 안정화, level은 Δ로 데이터 적응

[표 3-a] 정합성 점검: $\Delta = 0$일 때 목표 y 복원(Female)

- 내부 검증: $\Delta = 0$이면 선형예측자 $\eta(s, a)$가 문헌 목표 $y_{s,a}$를 복원해야 함

Sex	Age	y	$\alpha_0^{(\mathrm{GP})}$	β_{Male}	β_a	$\beta_{\mathrm{M}\times a}$	Sum	Match
F	< 20	-9.5813	-9.5813	0	0	0	-9.5813	OK
F	20–29	-8.6737	-9.5813	0	0.9077	0	-8.6737	OK
F	30–39	-8.9951	-9.5813	0	0.5862	0	-8.9951	OK
F	40–49	-9.2721	-9.5813	0	0.3092	0	-9.2721	OK
F	50–59	-9.4087	-9.5813	0	0.1726	0	-9.4087	OK
F	60–69	-9.6883	-9.5813	0	-0.1070	0	-9.6883	OK
F	70+	-9.5813	-9.5813	0	0.0000	0	-9.5813	OK

[표 3-b] 정합성 점검: $\Delta = 0$일 때 목표 y 복원(Male)

- 남성 strata에서는 β_{Male} 및 $\beta_{\text{Male}\times a}$가 더해져 목표 y 복원

Sex	Age	y	$\alpha_0^{(\mathrm{GP})}$	β_{Male}	β_a	$\beta_{\text{M}\times a}$	Sum	Match
M	< 20	-9.1614	-9.5813	0.4199	0	0	-9.1614	OK
M	20–29	-7.7868	-9.5813	0.4199	0.9077	0.4670	-7.7868	OK
M	30–39	-8.5372	-9.5813	0.4199	0.5862	0.0380	-8.5372	OK
M	40–49	-9.2304	-9.5813	0.4199	0.3092	-0.3782	-9.2304	OK
M	50–59	-9.9443	-9.5813	0.4199	0.1726	-0.9554	-9.9443	OK
M	60–69	-10.1519	-9.5813	0.4199	-0.1070	-0.8835	-10.1519	OK
M	70+	-10.3815	-9.5813	0.4199	0.0000	-1.2200	-10.3815	OK

Incidence 예측 확률 계산: $\eta_{\text{new}} \to \widehat{\Pi}_{\text{new}}$

- 사후표본에서 $\hat{\Delta}, \hat{\beta}$를 이용해 새로운 대상의 log-odds 계산
- 핵심 구조

$$\widehat{\Pi}_{\text{new}} = \text{logit}^{-1}(\eta_{\text{new}}) = \frac{1}{1 + e^{-\eta_{\text{new}}}}$$

- 예: $\eta_{\text{new}} = -2.0 \Rightarrow \widehat{\Pi}_{\text{new}} \approx 0.119$
- η_{new}는 성별/연령 및 상호작용에 대한 indicator 합으로 구성(앞 슬라이드의 η_i 구조와 동일)

Latency component: susceptible 집단의 생존함수 S_u

- 전체 생존함수

$$S_{\text{pop}}(t) = (1 - \Pi_i) + \Pi_i \, S_u(t \mid \mathbf{w}_i)$$

- Latency는 susceptible 집단에서의 전환시간 분포를 모델링
- 사건 정의(transition)
  - $\delta_i = 1$ if $\texttt{status} =$ "transition"
  - $\delta_i = 0$ if $\texttt{status} \in \{$"right_censoring", "remission"$\}$
- Latency 공변량: 성별만 사용 ($M_i = 1$ male, $M_i = 0$ female), 회귀계수는 γ로 표기

Cox latency: attained-age time scale & left truncation

- 도달 연령(attained age)을 시간축으로 사용
- 개인 i의 entry age: a_{i0}, 추적기간 t_i이면 exit age

$$a_{i1} = a_{i0} + t_i$$

- 도달연령 축에서 a_{i0}에서 위험집단 진입(left truncation), a_{i1}에서 사건/검열로 이탈
- 연령 구간(3개)

$$I_1 = [0, 20), \quad I_2 = [20, 30), \quad I_3 = [30, 50)$$

Cox latency: piecewise-constant baseline hazard

- susceptible 위험함수

$$h_u(a \mid M_i) = h_0(a) \exp\{\eta_i(a)\}$$

- baseline hazard: 연령구간별 상수

$$h_0(a) = \lambda_1 \mathbb{I}(a \in I_1) + \lambda_2 \mathbb{I}(a \in I_2) + \lambda_3 \mathbb{I}(a \in I_3), \qquad \lambda_k > 0$$

- 생존함수

$$S_u(a \mid M_i) = \exp\left\{ - \int_{a_{i0}}^{a} h_u(u \mid M_i)\, du \right\}$$

(구간별 합으로 닫힌형태 계산 가능)

Cox latency 후보모형: C0 vs C1 (sex effect)

- Model C0 (상호작용 없음; 성별 효과 상수)

$$\eta_i(a) = \gamma_M M_i, \qquad \mathrm{HR}_{M/F} = \exp(\gamma_M)$$

- Model C1 (연령구간별 성별 효과 허용)

$$\eta_i(a) = \gamma_M M_i + \gamma_{M\times I_2} M_i \mathbb{I}(a \in I_2) + \gamma_{M\times I_3} M_i \mathbb{I}(a \in I_3)$$

- 구간별 HR

$$\mathrm{HR}(I_1) = e^{\gamma_M}, \quad \mathrm{HR}(I_2) = e^{\gamma_M + \gamma_{M\times I_2}}, \quad \mathrm{HR}(I_3) = e^{\gamma_M + \gamma_{M\times I_3}}$$

Cox latency priors

- 성별 관련 회귀계수(약비정보적)

$$\gamma_M \sim \mathcal{N}(0, 10^2), \quad \gamma_{M \times I_2} \sim \mathcal{N}(0, 10^2), \quad \gamma_{M \times I_3} \sim \mathcal{N}(0, 10^2)$$

- baseline hazard(양수 제약을 로그 스케일에서 처리)

$$\log \lambda_k \sim \mathcal{N}(0, 10^2), \qquad k = 1, 2, 3$$

Mixture cure likelihood: Cox latency의 우도 기여

- 관측치: $(a_{i0}, a_{i1}, \delta_i)$ (attained-age scale)
- 사건($\delta_i = 1$)

$$L_i = \Pi_i \, h_u(a_{i1} \mid M_i) \, \exp\left\{ - \int_{a_{i0}}^{a_{i1}} h_u(u \mid M_i) \, du \right\}$$

- 검열($\delta_i = 0$)

$$L_i = (1 - \Pi_i) + \Pi_i \, \exp\left\{ - \int_{a_{i0}}^{a_{i1}} h_u(u \mid M_i) \, du \right\}$$

왜 AFT latency를 추가로 고려하는가? (Cox 보완)

- Cox latency는 구현/해석이 용이하나, 혼합 완치에서
  - 검열 비중이 크고 추적기간이 이질적이면 tail 추정이 보수적으로 작동할 수 있음
  - 결과적으로 S_u 외삽이 제한되어 cure fraction 과대평가 위험 가능
- AFT latency는 모수적 형태로 tail 외삽 가능
  - 공변량이 사건시간 스케일(가속/감속)에 직접 작용
  - 추적 불충분 영역에 대해 분포 형태를 통한 정보 공유 가능
- 따라서 Cox(C0/C1)를 기본으로, AFT(분포별; A0/A1)를 대안/민감도 분석으로 병행

AFT latency: 모형 정의(time-on-study scale)

- susceptible 잠재 사건시간 $T_i^* > 0$

$$\log T_i^* = \mu_i + \sigma\varepsilon_i, \qquad \sigma > 0$$

- baseline 연령그룹(3구간)

$$G_i \in \{< 20,\ 20\text{–}29,\ 30\text{–}49\}$$

- Model A0 (상호작용 없음)

$$\mu_i = \gamma_0 + \gamma_M M_i + \gamma_{G2}\mathbb{I}(G_i = 20\text{–}29) + \gamma_{G3}\mathbb{I}(G_i = 30\text{–}49)$$

- Model A1 (성별×연령 상호작용)

$$\mu_i = \mu_i(\text{A0}) + \gamma_{M\times G2} M_i \mathbb{I}(G_i = 20\text{–}29) + \gamma_{M\times G3} M_i \mathbb{I}(G_i = 30\text{–}49)$$

- 해석: $\exp(\gamma)$는 time ratio(가속 요인)

AFT latency: 오차분포(모형 가정)와 생존함수

- 분포 가정(3개 후보)
  - Log-normal: $\varepsilon_i \sim \mathcal{N}(0,1)$
  - Log-logistic: $\varepsilon_i \sim \text{Logistic}(0,1)$
  - Weibull(AFT): $\varepsilon_i \sim \text{EV}(0,1)$ (Gumbel)
- susceptible 생존함수(공통형)

$$S_u(t \mid \mathbf{w}_i) = \Pr\left(\varepsilon_i > \frac{\log t - \mu_i}{\sigma}\right)$$

- 분포 선택은 tail(외삽) 거동을 좌우 $\Rightarrow$ LOO/WAIC/PPC로 비교

AFT latency: priors & mixture likelihood

- 회귀계수(약비정보적)

$$\gamma_0, \gamma_M, \gamma_{G2}, \gamma_{G3}, \gamma_{M\times G2}, \gamma_{M\times G3} \sim \mathcal{N}(0, 10^2)$$

- 스케일 파라미터

$$\sigma \sim \text{half-Cauchy}(0, 2.5)$$

- 우도 기여(time-on-study; (t_i, δ_i))
  - 사건($\delta_i = 1$): $L_i = \Pi_i\, f_u(t_i \mid \mathbf{w}_i)$
  - 검열($\delta_i = 0$): $L_i = (1 - \Pi_i) + \Pi_i\, S_u(t_i \mid \mathbf{w}_i)$

Latency submodels: 적합 및 비교 전략

- Cox latency (attained-age): C0 (no interaction) vs C1 (interaction)
- Parametric AFT latency (time-on-study)
  - 분포: log-normal / log-logistic / Weibull
  - 각 분포별 A0(no interaction) vs A1(interaction)
- 비교 기준(사전 지정)
  - LOO, WAIC, posterior predictive checks(PPC)
  - tail(연구 종료 이후) 거동 및 cure fraction(=1-Π) 민감도 점검

[표 X-a] Prior master table: Incidence component

- Incidence에서는 문헌 기반 shape(contrast) + 데이터 기반 level(Δ) 설계

Component	Parameter group	Prior	Rationale / interpretation
Incidence	Fixed anchor: $\alpha_0^{(\mathrm{GP})}$	Fixed constant (not random)	문헌 기준 strata(Female < 2 logit anchor. 회귀계수 벡터에 포함. level은 Δ가 이동.
Incidence	Shift (Level): Δ	$\Delta \sim \mathcal{N}(0, 3.5^2)$	log-odds에서 약 ±7 이동(대략 수준) 허용. 일반인구 CHR-P 수 지 포괄.
Incidence	Shape: β_{Male}	$\beta_{\text{Male}} \sim \mathcal{N}(\mu_{\text{Male}}, 1.0^2)$	문헌 기반 성별 대비(로그 O mean으로 앵커링. $\sigma_\beta = 1$로 p data conflict 대응.
Incidence	Shape: β_{a_j}	$\beta_{a_j} \sim \mathcal{N}(\mu_{a_j}, 1.0^2)$	여성에서 기준 연령(<20) 대비 령대 contrast를 mean으로 반영
Incidence	Shape: $\beta_{\text{Male}\times a_j}$	$\beta_{\text{Male}\times a_j} \sim \mathcal{N}(\mu_{\text{Male}\times a_j}, 1.0^2)$	연령대별 남녀 격차 변화(=rat ORs)를 shape 정보로 반영.

[표 X-b] Prior master table: Cox latency (attained-age)

- Cox latency는 piecewise-constant baseline + 약비정보적 priors

Component	Parameter group	Prior	Rationale / interpretation
Cox latency	Baseline hazard: λ_k	$\log \lambda_k \sim \mathcal{N}(0, 10^2)$, $k = 1, 2, 3$	연령구간별 상수 구조만 부여, 크체는 diffuse. 양수 제약은 로그일에서 처리.
Cox latency (C0)	Covariate: γ_M	$\gamma_M \sim \mathcal{N}(0, 10^2)$	모든 연령구간에서 일정한 성별 (HR 상수).
Cox latency (C1)	Time-varying sex: γ_M	$\gamma_M \sim \mathcal{N}(0, 10^2)$	기준 구간 $I_1 = [0, 20)$에서의 효과.
Cox latency (C1)	Time-varying sex: $\gamma_{M \times I_2}$	$\gamma_{M \times I_2} \sim \mathcal{N}(0, 10^2)$	$I_2 = [20, 30)$에서의 추가 남성 $\mathrm{HR}(I_2) = \exp(\gamma_M + \gamma_{M \times I_2})$.
Cox latency (C1)	Time-varying sex: $\gamma_{M \times I_3}$	$\gamma_{M \times I_3} \sim \mathcal{N}(0, 10^2)$	$I_3 = [30, 50)$에서의 추가 남성 $\mathrm{HR}(I_3) = \exp(\gamma_M + \gamma_{M \times I_3})$.

[표 X-c] Prior master table: AFT latency (time-on-study) & distributions

- AFT는 위치(로그시간) 회귀 + 스케일 σ + 분포 선택(모형 비교)

Component	Parameter group	Prior / assumption	Rationale / interpretation
AFT latency	Regression effects	γ's $\sim \mathcal{N}(0, 10^2)$	위치 모수(로그시간 평균)에 대 비정보적 설정.
AFT latency	Scale: σ	$\sigma \sim$ half-Cauchy$(0, 2.5)$	$\sigma > 0$ 제약 + heavy-tail 약정
AFT latency	Error distribution	log-normal / log-logistic / Weibull(AFT)	분포 선택이 $S_u(t)$ tail/외삽 특 규정. LOO/WAIC/PPC로 비교

1 Introduction

2 Methods and Materials

3 Results

4 Discussion

1 Introduction

2 Methods and Materials

3 Results

4 Discussion

Thank you!